

학번	이름
202455463	최지은

1. 평가 목적

본 보고서는 Strikers 1945+ 스타일의 스크롤 슈팅 게임 개발에서 Claude Code가 생성한 코드의 품질을 두 가지 방법으로 평가하고, 사람-기계 평가 일치도를 측정한 결과를 담았다.

- **평가 방법 1 (M1):** 3차원 다차원 Rubric — Correctness/Completeness/Visual Design 각 1~5점으로 평가한 후 평균으로 점수를 산출하였다.
- **평가 방법 2 (M2):** 종합 Rubric — 케이스 전체를 1~5점으로 단일 점수로 평가하였다.
- **일치도 지표:** Cohen's Kappa (`sklearn.metrics.cohen_kappa_score`), `weights=None` / `weights='quadratic'` 두 가지로 진행하였다.

2. 평가 방식 및 선택 이유

자세한 평가 기준은 eval 폴더의 `rubric.md`에 나와있다.

방식 1 : 다차원 Rubric (M1)

차원	의미
Correctness	구현이 버그 없이 의도대로 동작하는가
Completeness	요구사항 전체를 빠짐없이 구현했는가
Visual Design	시각 효과/HUD/애니메이션이 게임 스타일에 맞게 구현되었는가

게임에서는 '동작 정확도', '기능 완성도', '시각 표현'이 중요하기 때문에 개별적으로 평가하였다. 차원별 분리 평가로 부분적 성공과 실패를 세밀하게 포착할 수 있었다.

방식 2 : 종합 Rubric (M2)

- 게임 전체를 하나의 점수로 평가. 1~5점 각각에 명확한 기준을 명시(edge 케이스, UI 가독성, 클리어 가능 여부 등)하여 평가자 간 기준 편차를 줄였다.
- 선택 이유: 다차원 평가는 차원 간 가중치 결정이 필요하지만, Rubric은 전체적 완성을 직관적으로 표현한다. 두 방식을 함께 사용함으로써 세부 진단과 전체 품질 평가를 모두 수행한다.

3. 사용 라이브러리

Claude Code CLI (LLM-as-Judge)

LLM 자동 평가는 외부 API 호출 없이 **Claude Code 세션 내에서 직접** 수행했다. Claude Code의 fork agent 메커니즘을 활용하여, 각 테스트케이스 백업 폴더의 핵심 JS 파일을 Read 도구로 직접 읽고 rubric 기준에 따라 코드를 정적 분석하여 점수(correctness, completeness, visual_design, m2)를 산출한 뒤 `eval/llm_scores.json`에 저장했다. `anthropic` Python SDK나 별도 API 키는 사용하지 않았다.

scikit-learn (`sklearn`)

```
from sklearn.metrics import cohen_kappa_score
kappa_unweighted = cohen_kappa_score(human_scores, llm_scores, weights=None)
kappa_quadratic = cohen_kappa_score(human_scores, llm_scores,
weights='quadratic')
```

사람 점수(person_eval.md)와 LLM 점수(llm_scores.json)를 리스트로 변환하여 `cohen_kappa_score`에 전달했다.

4. 점수 비교

4-1. M1 - Correctness

TC	폴더	사람	LLM	차이(사람-LLM)
TC-01	001_20260620_170745	2	3	-1
TC-02	002_20260620_172127	2	4	-2
TC-03	003_20260620_173130	2	5	-3
TC-04	004_20260620_173609	3	2	+1
TC-05	005_20260620_174938	3	5	-2
TC-06	006_20260622_094525	4	5	-1
TC-07	007_20260622_095416	4	5	-1
TC-08	008_20260622_100337	4	5	-1
TC-09	009_20260622_100841	5	5	+0
TC-10	010_20260622_101532	5	5	+0

4-2. M1 - Completeness

TC	폴더	사람	LLM	차이(사람-LLM)
TC-01	001_20260620_170745	3	4	-1
TC-02	002_20260620_172127	3	5	-2
TC-03	003_20260620_173130	3	5	-2
TC-04	004_20260620_173609	3	3	+0
TC-05	005_20260620_174938	3	5	-2
TC-06	006_20260622_094525	4	5	-1
TC-07	007_20260622_095416	4	5	-1
TC-08	008_20260622_100337	4	5	-1
TC-09	009_20260622_100841	5	5	+0

TC	폴더	사람	LLM	차이(사람-LLM)
TC-10	010_20260622_101532	5	5	+0

4-3. M1 - Visual Design

TC	폴더	사람	LLM	차이(사람-LLM)
TC-01	001_20260620_170745	2	4	-2
TC-02	002_20260620_172127	2	3	-1
TC-03	003_20260620_173130	2	5	-3
TC-04	004_20260620_173609	3	3	+0
TC-05	005_20260620_174938	3	4	-1
TC-06	006_20260622_094525	3	4	-1
TC-07	007_20260622_095416	3	5	-2
TC-08	008_20260622_100337	4	5	-1
TC-09	009_20260622_100841	4	5	-1
TC-10	010_20260622_101532	4	5	-1

4-4. M1 평균 및 M2 종합 비교

TC	폴더	M1 사람	M1 LLM	M2 사람	M2 LLM
TC-01	001_20260620_170745	2.33	3.67	2	3
TC-02	002_20260620_172127	2.33	4.00	2	4
TC-03	003_20260620_173130	2.33	5.00	2	4
TC-04	004_20260620_173609	3.00	2.67	3	3
TC-05	005_20260620_174938	3.00	4.67	3	5
TC-06	006_20260622_094525	3.67	4.67	3	5
TC-07	007_20260622_095416	3.67	5.00	4	5
TC-08	008_20260622_100337	4.00	5.00	4	5
TC-09	009_20260622_100841	4.67	5.00	4	5
TC-10	010_20260622_101532	4.67	5.00	5	5

5. Cohen's Kappa 결과

기준	weights	Kappa	해석
M2 종합	None (unweighted)	0.0244	작은 일치

기준	weights	Kappa	해석
M2 종합	quadratic	0.3421	보통 일치
Correctness	None (unweighted)	-0.0256	우연보다 낮은 일치
Correctness	quadratic	0.3293	보통 일치

6. weights 유무에 따른 차이 설명

- **weights=None**
unweighted Kappa는 점수 차이의 크기를 무시한다. 1점 차이든 4점 차이든 동등하게 '불일치'로 처리함을 볼 수 있다
- **weights='quadratic'**
가중 Kappa는 불일치 정도에 이차 가중치를 적용한다. 1점 차이는 가볍게, 4점 차이는 16배 무겁게 패널티를 준다. 5점 척도처럼 순서가 있는 데이터에서 '큰 불일치가 드물다'면 unweighted보다 높은 값이 나오는 경향이 있다.

본 평가에서는 M2 기준 unweighted=0.0244, quadratic=0.3421로, quadratic이 더 높게 나왔다. 이는 사람과 LLM의 큰 의견 불일치(3점 이상 차이)가 적다는 의미로 볼 수 있다

7. 사람-기계 일치도 분석

전체 10개 케이스에 대해 M2 종합 점수 기준 Cohen's Kappa는 unweighted=0.0244, quadratic=0.3421이다.

- LLM 평가의 특성
 - LLM(claude-sonnet-4-6)은 코드 정적 분석 기반으로 평가했다. 실제 브라우저 실행을 통한 동적 테스트 없이, 코드 로직과 함수 구조, 패턴 구현 여부 등으로 점수를 산출했다.
 - 이로 인해 시각적인 디자인 차원에서 LLM은 Canvas 렌더링 코드의 존재 여부만 판단하며, 실제 화면에서의 자연스러움과 가독성은 반영되지 않는다.
 - Correctness 차원에서 LLM은 확실한 버그(변수 미초기화, 조건 오류 등)는 잘 잡아내지만, 미묘한 타이밍 이슈나 브라우저 특정 버그는 놓칠 수 있다.
- 일치도 해석
Kappa가 0.4 미만으로 일치도가 낮다. LLM 정적 분석과 사람의 실행 기반 평가 간에 체계적 차이가 존재할 가능성이 높다. LLM은 코드가 존재하느냐에 집중하는 반면, 사람은 동작의 자연스러움과 게임 플레이 경험까지 반영하였기 때문에 이런 차이가 보인다고 생각한다. 특히 시각 디자인과 난이도 체감처럼 주관적 요소가 강한 항목일 수록 사람과 LLM 평가자 간의 괴리가 커질 것으로 예상된다.

8. LLM 평가 근거

TC	LLM 평가 근거
TC-01	최초 구현으로 기본 게임 루프·배경·적·보스·HUD 등 핵심 시스템이 갖춰져 있다. 그러나 squadDone()이 HOLD 단계에서도 true를 반환하여(phase!=='DELAY'&&phase!=='ENTER' 조건 누락) 편대 전원 사망 시 wave가 조기 클리어되는 버그가 있다. 보스 HP 공식이 180+tier*65(스펙과 불일치)이고 티어별 스케일링 미구현. CSS가 game.html 내 인라인 <style>에 포함되어 있으며 키 색상이 #333(어두워 거의 보이지 않음).
TC-02	CSS를 style.css로 분리하고 game.html을 순수 HTML 셀로 리팩터링. 가 올바르게 추가되고 인라인 <style> 제거됨. JS 17개 파일 로드 순서도 정상. 리팩터링 자체는 완전하고 회귀 없음. 다만 squadDone

TC LLM 평가 근거

	HOLD 버그는 그대로이며, style.css의 .key{color:#333}이 유지되어 키 가시성이 낮다.
TC-03	style.css의 키 색상을 #333→#aaa로 개선하여 키 피드백 가시성을 크게 높임. .key small: #2b2b2b→#777, .key.active small: #bb6600→#cc8800, #keyBar 배경-테두리도 약간 밝아짐. CSS 변경 사항이 정확하고 완전하다. M2는 4 — 작지만 명확한 시각적 개선.
TC-04	formations.js의 squadDone이 TC-01보다 오히려 퇴행됨: TC-01은 !=='DELAY'&&!='ENTER' 이중 조건이었으나 TC-04는 !=='DELAY' 단일 조건으로 변경되어 ENTER 단계 전원 사망 시에도 squadDone=true가 되는 더 심각한 버그를 도입. 조작법 색상 변경은 hud.js에서 확인되지 않음(formations.js만 변경됨 확인). 핵심 편대 FSM의 회귀로 correctness 2.
TC-05	squadDone 버그가 두 부분 모두 완전히 수정됨. (1) squadDone: phase==='ATTACK'&&every(!alive) — ATTACK 단계 한정. (2) updateSquad dead-squad 핸들링: ENTER→HOLD 전이 후 holdT 카운트다운 →ATTACK 전환. CLAUDE.md 스펙과 정확히 일치. 시각 변경 없음. M2는 5 — 게임 진행 로직의 핵심 버그 완전 해결.
TC-06	보스 티어별 스케일링이 스펙과 정확히 일치: $HP=80+tier90(tier1\rightarrow170, tier4\rightarrow440)$, $speedMul=0.6+tier0.1$, $shootMul=1.8-tier*0.2$. spawnBossNow에서 계산, updateBoss/bossShoot에서 각각 적용됨. bossSpawnMinions phase2+ 미니언 소환도 정상. 시각 변경 없음. M2는 5 — 4단계 난이도 곡선이 명확해짐.
TC-07	보스 특수 공격 3종 완전 구현: CROSS(45°/135°/225°/315° 4방향탄), BURST(플레이어 방향 3발 C형 부채꼴), VOLLEY(플레이어 방향 5발 집중). 주기 [7s/5.5s/4s] 스펙 일치. 페이즈 전환 시 즉시 bossSpecial() 발동. Phase 2 dodgeT(0.8~1.8s) 지그재그 추가. bossSpawnMinions: phase3=3기, tier3+ phase3=C형. 각 특수 공격에 CROSS!/BURST!/VOLLEY! FX 텍스트 표시.
TC-08	파워업 아이템 3종(R/N/S) 완전 구현: applyItem에서 rapidT/pierceT/shieldT 설정. 드롭 확률 R:4%, N:3%, S:3%. ITEM_COLS에 7종 모두 포함. HUD 타이머:  SHIELD(#00ff88),  RAPID(#0ff),  PIERCE(#c0f) 스택 표시, 쉴드 3초 미만 시 깜빡임 효과. 아이템 픽셀아트 다이아몬드 형태에 타입 레터 표시. 일시정지 화면 개선 포함.
TC-09	편대 대형 3종 추가: CIRCLE8(타원형 8기), DIAMOND6(다이아몬드 6기), ZIGZAG6(지그재그 6기). 진입 경로 3종 추가: SNEAK_L(좌벽), SNEAK_R(우벽), LOOP(급강하-복귀). waves.js도 동시에 randWave(n)으로 전환하여 9개 대형×9개 진입 경로 전체가 즉시 게임에 활용됨. maxSp 기반 피벗 X 범위 제한으로 화면 밖 배치 방지. 편대 배치 다양성 대폭 증가.
TC-10	최종 통합 상태. TC-09 대비 constants.js에 RAPID_DUR=8, PIERCE_DUR=10, SHIELD_DUR=12 상수가 명시적으로 추출됨. CLAUDE.md가 모든 기능을 완전히 반영한 최종본으로 업데이트. waves.js, formations.js 등 핵심 로직은 TC-09와 동일. 파이어볼 관통(pierce:true, hset:Set), 쉴드 피격 흡수(hitPlayer shieldT 초기화) 등 모든 메커니즘 통합 정상.